الدكتور هيعمل مراجعه سريعه كدا على الليرنجن ثيوري ...

Q&A

Q: Why do we shuffle the examples in SGD?

This is how we do sampling without replacement

- Theoretically we can show sampling without replacement is not significantly worse than sampling with replacement (Shamir, 2016)
- 2. Practically sampling without replacement tends to work better

Q: What is "bias"?

A: That depends. The word "bias" shows up all over machine learning! Watch out...


- 1. The additive term in a linear model (i.e. b in $w^Tx + b$)
- 2. Inductive bias is the principle by which a learning algorithm generalizes to unseen examples
- Bias of a model in a societal sense may refer to racial, socioeconomic, gender biases that exist in the predictions of your model
- 4. The difference between the expected predictions of your model and the ground truth (as in "bias-variance tradeoff")

طيب بسم الله .. احنا عاوزين نفكر في السامبل كومبلكستي .. في آخر مره احنا وصلنا لأول نظريه

Sample Complexity Results

Definition 0.1. The **sample complexity** of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to 1).

Four Cases we care about...



هنا انت عندك upper bound علي ال true error اللي انت متعرفهوش بناءَ علي ال training error الي احنا بنبقا عارفينو ... طيب الدكتور حاطط مثال وعاوزنا نفكر في النظريه كإنها مثال .. والمثال هنا هو هيبقا hypotheses class of conjunctions .. فاحنا هنقول ان H is a class of .. والفيكتورز إكس دول هيبقا اصصفار ووحايد ..

Example: Conjunctions Question: Suppose H = class of A. $10*(2*ln(10)+ln(100)) \approx 92$ conjunctions over x in {0,1}M B. $10*(3*ln(10)+ln(100)) \approx 116$ $10*(10*ln(2)+ln(100)) \approx 116$ Example hypotheses: D. $10*(10*ln(3)+ln(100)) \approx 156$ $\rightarrow h(x) = x_1(1-x_2) x_2$ 100*(2*ln(10)+ln(10)) ≈ 691 $\rightarrow h(x) = X_1(1-X_2) X_4(1-X_5)$ 100*(3*ln(10)+ln(10)) ≈ 922 100*(10*ln(2)+ln(10)) ≈ 924 If M = 10, $\varepsilon = 0.1$, $\delta = 0.01$, how H. $100*(10*ln(3)+ln(10)) \approx 1329$ many examples suffice (+ Lay(00)] according to Theorem 1?


طيب الدكتور بيقول في المثال ده اننا عاوزين نجيب عدد الامثله اللي هتبقا كفايه عشان تحقق theorem 1. الدكتور اتكلم علي ان المشكله كلها في حساب size of H الله هو في النظريه عندك | H | المهم هنا الدكتور قال هو الحجم اصلا عباره عن ايه ... عباره عن المسكله كله هنا هيبقا الله size of H الله وقال الدكتور كمل كلامه وقال ان في 3 اوبشنز لكل فاريبل من ال wariables اللي عندك .. كل فاريبل هنا هيبقا الدكتور كمل كلامه وقال ان في 3 اوبشنز لكل فاريبل من اله wariables اللي عندك .. كل واحد ليه 3 اختيارات ليه 3 حالات . يا إما included but negated هيبقا المهم هيبقا عندك .. عندك معناه الله المثال ده .. معناه الله المهم هيبقا ليهم صفر تريننج ايرور علي الداتا سبت بتاعتك اللي هي 156 مثال ... وهيبقا ليهم معنان نجيب البرفورمنس اللي احنا عاوزينو .. الحاجه الحلوه هنا ان علي ارض الواقع احنا مش بنستخدم النظريه ديه عشان نحدد عدد الأمثله اللي هنحتاجها عشان نجيب البرفورمنس اللي احنا عاوزينو .. هي بس مجرد بتديك sense كدا انك تقول انت محتاج كام مثال يعني انت ممكن تحتاجهم عشان تجيب برفورمنس كويس تحت شوية assumptions قالمم المره اللي فاتت تحت ال PAC model ...


طيب الحاجه التانيه اللي هنقول عليها هي ال Realizable vs Agnostic case .. ال Realizable setting هنا انت عندك ال star ال hypotheses ... انما ال Agnostic setting ... انما ال Agnostic setting ... هي ان برضو ال c star in the hypotheses space أو انها مش في ال space احنا مش متأكدين ... " عشان نبقا ناس كوريكتور " ..

طيب السؤال هنا عشان نخلي نظريه رقم 1 ديه ليها قيمه يعني احنا فعلا بنحتاج نجيب قيم الإبسيلون و قيم الدلتا ... هنا انت بتختار هم بايدك ... طيب تعال نرجع للفرق ما بين ال Realizable vs Agnostic سيب اللي عاوزين نقولو هنا ان ال Agnostic case بتيجي لما انت بتفكر في ان أياً كان الفانكشن اللي عملت جينيريشن للداتا .. هي مش معاك في الهيبوثيسيز سبيس ... فال finite H هنا احنا لو فكرنا مثلا زي في ال clear finite H هنا مثلا لو عندك ماكس ديبث 10 .. ليه Class of decision اللي على الهيبوثيزيز اللي عندك ... بس فعلياً كل الداتا سيتس اللي هتعمل تريننج عليها .. هتبقا في ال Agnoistic للي عمل ال labeling هو انسان .. مش شجره .. "انا شجره" .. فاللي بنقولو في ال Agnostic .. في السلايد الجايه

Sample Complexity Results

Definition 0.1. The **sample complexity** of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to 1).






Sample Complexity Results

Definition 0.1. The **sample complexity** of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to 1).

Four Cases we care about...





طيب لو عندنا linear decision boundary عندنا انفنت نامبر اوف هايبوثيزيز ..

Sample Complexity Results

Definition 0.1. The **sample complexity** of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to th

Four Cases we care about...





لو جينا نفكر في التعريف ده بيقول ايه .. هو بيقول ان ال hypotheses space بي shatter S لو عدد ال splitting المتاح ليك هو بيساوي 2^s ... فال shatter that particular dataset S ... فال circular decision boundary

طيب هنعرف ايه هو ال VC-dimension .. ال VC-dimension بتاع ال hypotheses space هو حجم أكبر VC-dimension تقدر تقسّمها باستخدام ال H .. السؤال هنا ازاي نجيب VC-dimension بتاع VC-dimension ..

Shattering, VC-dimension

Definition:


H[S] - the set of splittings of dataset S using concepts from H. H shatters S if $|H[S]| = 2^{|S|}$.

A set of points S is shattered by H is there are hypotheses in H that split S in all of the $2^{|S|}$ possible ways; i.e., all possible ways of classifying points in S are achievable using concepts in H.


Definition: VC-dimension (Vapnik-Chervonenkis dimension)

The VC-dimension of a hypothesis space H is the <u>cardinality of</u> the largest set S that can be shattered by H.


If arbitrarily large finite sets can be shattered by H, then $VCdim(H) = \infty$



فعشان تثبت ال VC-Dimension اللي انت محتاج تقول انو موجود هو example dataset ال الله تقدر ت shatter .. وديه أكبر داتا سبت ال shatter .. "انا مش فاهم " ... أول سؤال از اي نثبت رقم 1 في الصوره اللي فوق:



اللي عاوزين نعملو ناو هو نثبت رقم 2:



اللي بنقولو هنا هو ان لو عندنا مثلا في حالة A .. لو انت تخيلت ان عندك داتا سيت من الفورم اللي بالشكل ده .. و البوينتس كانت ان اللي في النص بس هو الموجب و كل اللي الكورنرز كانو سالب ... في الحاله ديه مفيش linear decision boundary بيقدر ي convex hull بيقدر و مش مهم ال plus point ديه فين جوا ال convex hull الو ايه هو الكونفجريشن بتاع ال 3 نقط التانيين .. فأي داات سيت هتجيبهالي مش هيبقا في boundary ..

الدكتور هيحط سايد نوت عباره عن سؤال ..

Side Note Q: What is dataset of size d=3

that can't be shattered?

A: 1

طيب اللي عاوزين نوضحو ان في فرق ما بين ال distinction between there exists and for all .. في ال VC-dimension .. لما بنيجي نثبت ال VC-Deimension .. في ال VC-dimension .. الدكتور VC-Deimension بيعتمد علي ال d+1 منقدرش نشاتر .. الدكتور بس حب يوضح السلايد الجايه ... ان ال VC بتعتمد علي exists انما ال shattering بيعتمد علي ال forall ..

VCDim

 Proving VC Dimension requires us to show that there exists (∃) a dataset of size d that can be shattered and that there does not exist (∄) a dataset of size d+1 that can be shattered


Shattering

 Proving that a particular dataset can be shattered requires us to show that for all (∀) labelings of the dataset, our hypothesis class contains a hypothesis that can correctly classify it

طیب فی امثله تانیه:

Shattering, VC-dimension


If the VC-dimension is d, that means there exists a set of d points that can be shattered, but there is no set of d+1 points that can be shattered.



Sample Complexity Results


Definition 0.1. The **sample complexity** of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to 1).


Four Cases we care about...




طيب الدكتور بيقول احنا لحد دلوقت بنتكلم علي عدد الأمثله اللي هنحتاجها .. دلوقت هنخش في اتجاه مختلف شويه هو ال slt اللي هو statistical للربسيلون .. ده بيحط learning theory ... انك هتحل للربسيلون .. ده بيحط upper bound على النروو إيرور ل fixed number of examples ...

SLT-style Corollaries





Corollary 1 (Realizable, Finite $|\mathcal{H}|$). For some $\delta>0$, with probability at least $(1-\delta)$, for any h in \mathcal{H} consistent with the training data (i.e. $\hat{R}(h)=0$),



We can obtain similar corollaries fo each of the theorems...

SLT-style Corollaries

Corollary 1 (Realizable, Finite $|\mathcal{H}|$). For some $\delta>0$, with probability at least $(1-\delta)$, for any h in \mathcal{H} consistent with the training data (i.e. $\hat{R}(h)=0$),

$$R(h) \leq \frac{1}{N} \left[\ln(|\mathcal{H}|) + \ln\left(\frac{1}{\delta}\right) \right]$$

Corollary 2 (Agnostic, Finite $|\mathcal{H}|$). For some $\delta > 0$, with probability at least $(1 - \delta)$, for all hypotheses h in \mathcal{H} ,

$$R(h) \le \hat{R}(h) + \sqrt{\frac{1}{2N} \left[\ln(|\mathcal{H}|) + \ln\left(\frac{2}{\delta}\right) \right]}$$

SLT-style Corollaries

Corollary 3 (Realizable, Infinite $|\mathcal{H}|$ **).** For some $\delta > 0$, with probability at least $(1 - \delta)$, for any hypothesis h in \mathcal{H} consistent with the data (i.e. with $\hat{R}(h) = 0$),


$$R(h) \le O\left(\frac{1}{N}\left[\mathsf{VC}(\mathcal{H})\ln\left(\frac{N}{\mathsf{VC}(\mathcal{H})}\right) + \ln\left(\frac{1}{\delta}\right)\right]\right)$$
 (1)


Corollary 4 (Agnostic, Infinite $|\mathcal{H}|$ **).** For some $\delta > 0$, with probability at least $(1 - \delta)$, for all hypotheses h in \mathcal{H} ,

$$R(h) \le \hat{R}(h) + O\left(\sqrt{\frac{1}{N}\left[\mathsf{VC}(\mathcal{H}) + \ln\left(\frac{1}{\delta}\right)\right]}\right) \tag{2}$$

طيب السؤال المهم .. ازاي هنعمل model selection:

الموديل سيليكيشن هو انت عاوز تفكر في empirical risk minimization ..





Decision Functions - Perception: $h_{\Theta}(\vec{x}) = sign(\vec{\Theta}^T \vec{x})$ - Linear Regressih: ho(x)= BTX Discoininter Models: ho(x) = argunex B(y1)x) Generative Models: ho(x) = azurex po(x,y) - joint distr.

Naive Bayes p(x,y) = p(y) # p(xm/y)

- 1/1/1 C 1 .01 5 (os. Ros. p(y=1/x)= o (OTX) -NN for dossisfection: $p(y|\vec{x}) = \sigma(W^{(2)T}(W^{(1)T}\vec{x} + b^{(0)}) + b^{(2)})$ OMLE: $J(\theta) = -\frac{1}{2} \log p(x^{(i)}, y^{(i)})$ Onditional Discrete: $J(\theta) = -\frac{1}{2} \log p(y^{(i)}/x^{(i)})$ 2 L2 Reg: 5'(0) = 5(0) + 7/10/12 4 LI Reg: " + 7/10/1, Opt Method - Gedient Descut 0-175(0) 0 4-0- } VJ(i)(0) for i~ Unifam({1, -1/8}) J(0) = 1 5 J(0(0) - Mini-batch SED - Closed Form partial

O compute partial derintues

O set to sero and some